

# Vese CT Felvételek Osztályozása Deep Learning Algoritmusok Felhasználásával (2023)

Fogti István, Dau Quang Phong, Gáspár Bálint

**Absztrakt** — A vese tumor jelenti napjainkban az egyik leggyakoribb halálos kimenetelű megbetegedést, illetve a hetedik leggyakoribb rosszindulatú daganattípust nők és férfiak körében egyaránt. A halálos kimenetel elkerülésének leghatásosabb módja a megelőzés, amelyben napjainkban nagyon fontos szerepet játszanak a Deep Learning algoritmusok. A DL segítségével nagyon sok idő, pénz, és energia spórolható az egészségügyi szektorban azáltal, hogy bizonyos felvételeket automatikusan ki lehet zárni, egyértelműen nem tumor gyanúsak.

Ezen egyetemi projekt során kísérletet tettünk mi is egy ilyen modell megvalósítására. A cél eléréséhez egy kaggle adathalmazt használtunk, amely egy PACS (Picture archiving and communication system) által Dakka különböző korszakaiban készült felvételeket tartalmaz, már kész felállított diagnózissal. A modellünk egy 12 rétegből álló módosított konvolúciós háló.

## I. BEVEZETŐ

A mai világban rengeteg ember veszti el életét különböző betegségekben, mint a cukorbetegség, daganatok, illetve különböző szív, tüdő és vese betegségek. Az elhunyt személyek száma csökkenthető megfelelő megelőző intézkedéssel, mint a korai diagnózis. Ennek az egyik lépése a többféle orvosi képek felismerése, mint a röntgen, MRI (magnetic resonance image), CT (computed tomography) vagy ultrahang felvételek. Az elmúlt években rengeteget fejlődött géptanulás a kép megértés területén. Az egyik ilyen népszerű gépi tanulást alkalmazó eszköz a konvolúciós neurális hálózat (CNN), amely automatikusan megtanulja és kinyeri a képmegértéshez szükséges jellemzőket. A CNN a 2012-es években vált népszerűvé az AlexNet-nek köszönhetően, ami rekord pontossággal és alacsony hibával nyerte meg az ImageNet versenyt. A CNN fő alkalmazási területei a kép- és jelfeldolgozás, az NLP (természetes nyelvfeldolgozás) és az adatelemzés. (Sarvamangala & Kulkarni, 2022)


## II. TÉMATERÜLET ISMERTETÉSE, KORÁBBI MEGOLDÁSOK

Az objektumfelismerés egy olyan módszer, amely azonosítja az osztálypéldányt, amelyhez az objektum tartozik. Lehet egy-, illetve többosztályos felismerés. Az orvosi képeken gyakran alkalmaznak objektumfelismerést, mivel pontosan felfedez különböző betegségeket. CNN használatával egyszerűen fel lehet fedezni egy kép jellemzőit és képeken található különböző objektumok ezek alapján ismerhetők fel. A CNN-ek kísérleti alapon, próba-hiba alapon választják ki a változókat. (Alzu'bi és mtsai., 2022)

2014-ben Ghalib és munkatársai tanulmányt végeztek, amely mélytanulást alkalmazott vesetumorkok felismerésében CT felvételeken. Az algoritmus képes volt a zajokat azonosítani és azokat eltávolítani. A kísérlet eredményei alapján a modell jó eredménnyel különböztette meg az egészséges vesét a betegtől, 0,85 másodperc átlagos számítási idővel. (Ghalib és mtsai., 2014)

2020-ban Zabihollahy és munkatársai tanulmányt készítettek a vese tumorok felismeréséről mély tanulási alkalmazásával CT felvételeken. CECT (contrast-enhanced computed tomography) képeken alkalmaztak különböző CNN típusokat, mint félautomatizált többségi szavazással működő 2D-CNN, teljesen automatizált 2D-CNN és 3D-CNN, osztályozási feladatra. 315 beteg adatait alkalmazták, amelyben 77 jóindulatú és 238 rosszindulatú vese tumor volt található. A modell 83,75%-os pontossági, 89,05%-os precíziós és 91,73%-os visszahívási értékeket produkált. (Zabihollahy és mtsai., 2020)

Szintén 2020-ban Yap és munkatársai kutatást végeztek a vese tumorok CT képek osztályozásáról gépi tanulási segítségével. 735 tumorral rendelkező beteg CT-vizsgálatát használták fel, amelyben az adathalmaz 196 jóindulatú és 539 rosszindulatú esetet tartalmazott. Két radiológus szakértővel együttműködve manuálisan szegmentálták a felvételeket, ahol a jellemzőket alak- és textúramátrixok alapján vonták ki. Azonban CNN helyett Random Forestet és AdaBoostot alkalmaztak. A kísérlet eredményei alapján a Random Forest 0,68-0,75 AUC-értékeket ért el.



### III. RENDSZERTERV, MEGOLDÁS

Ebben a részben leírásra kerül az általunk használt adathalmaz, illetve a módosított CNN hálónk, amelyet a felvételek osztályozására használunk. A megoldás során google colabot használtunk a hálónk tréningeléséhez, illetve keras frameworkot.

Az adathalmazunk a PACS (Picture archiving and communication system) által Dukka különböző kórházaiban készült felvételeket tartalmaz, már kész felállított diagnózissal. Összesen 12446 képet tartalmaz, amelyből 3709 cisztát, 1377 vesekövet, 2283 pedig tumort tartalmaz. A maradék 5077 felvételen egészséges vesék láthatóak (Mehedi, és mtsai., 2022).

Első lépésként az adatok címkéit one-hot enkódolt formátumba konvertáljuk rögtön betöltés után. Ezután az adathalmaz train, teszt, és validációs halmazokra való szétszedése következik. A mi esetünkben az adatok 80%-a lesz trainelésre felhasználva, 10-10% pedig validációra, és tesztelésre. Ezután következik az adatok összekeverése és vizualizálása. A képekből kiderül, hogy az adathalmaz különböző tengelyek mentén készített keresztmetszeteket tartalmaz. Vizualizáció után a képeket normalizáljuk. A teljesítmény optimalizálásához prefetchet használunk, hogy az adatok az első epoch után a memóriában maradjanak, így megelőzve azok folytonos ki és betöltését. Ezután következik a hálónk felépítése.

A feladat megoldásához konvolúciós neurális hálózatot használtunk. A CNN alapvetően konvolúciós és pooling rétegekből áll, amelyek között lehetnek további rétegek, például Dropout, vagy BatchNorm. Az utolsó rétegek a hálózatban gyakran előrecsatolt rétegek, melynek feladata a megtanult jellemzők osztályba elhelyezése.

A fenti ábrán látható egy általános CNN felépítése. (Zainkó Cs., Gyires-Tóth B., 2021)

A háló létrehozására a Keras Sequential osztályát alkalmaztuk.

A Keras egy népszerű Python mesterséges intelligencia könyvtár, mivel erőteljes építőelemeket szolgáltat mélytanuló hálózatok számára. Emellett támogatja mind a CPU, mind a GPU általi gyorsítást, amely jelentősen segít a modell sebeségében. A Sequential használatával a felhasználó egyszerűen tud a modellhez új rétegeket hozzáadni, vagy a meglévő rétegeket módosítani. (Ketkar N., 2017)

A háló 12 rétegből áll az alábbi felépítésben: Conv2D, MaxPooling2D, Conv2D, MaxPooling2D, Dropout, Conv2D, MaxPooling2D, Conv2D, MaxPooling2D, Flatten, Dense, Dropout, Dense.

A Conv2d a konvolúciós réteg, amelynek feladata a bemenetre jellemzők megtanulása.

A Maxpooling2D a pooling réteg, amelynek feladata a feature map dimenzióinak csökkentése, ami gyorsítja és egyszerűsíti a jövőbeli számításokat. Alapvetően két konvolúciós réteg között helyezkedik el.

A Flatten réteg egy több-dimenziós mátrixot alakít át egy egy-dimenziós mátrixra, amelyet a fully connected réteg értelmezni tud.

A Dense egy fully connected réteg, amelynek feladata az előzetes rétegekből kinyert jellemzők alapján predikciót hozni.

A Dropout funkció feladata a túltanulás elkerülése.


A modellünk a konvolúciós és pooling rétegekben a ReLU (Rectified Linear Unit) aktivizációs függvényt alkalmaz, ami egy lineáris korrekció. Képlete:  $g(x) = \max(0, x)$ . A negatív értékeket 0-ra módosítja, a pozitív értékeket nem módosítja. A számítások egyszerűsítése elősegíti a gyorsabb tanulást. (Guo T., és mtsai., 2017) Az utolsó fully connected réteg softmax aktivizációs függvényt használ, ami több sigmoid függvény kombinációja. A sigmoid függvénnyel ellentétben nem csak bináris osztályozáshoz használható, hanem több osztályosra is. (Sharma S., Athaiya A., 2017)

Az általunk kitalált háló különlegessége abban rejlik, hogy nem tartalmaz annyi réteget, mint a korábbi kutatásokban felhasznált modellek, és ennek ellenére hoz nagyon jó eredményeket. A modellünk 12 rétegből épül fel, amelyeknél szempont volt az egymást követő konvolúciós rétegek közt növekvő filterszám az egyes tulajdonságok egyre magasabb szintű részletezéséhez. Az utolsó rétegek hasonlóan a többi megoldáshoz egy "Flatten", két "Dense", és még egy "Dropout" réteget tartalmaznak.

A megvalósításhoz továbbá keras callbackeket is használtunk. Az early stopping miatt a modell amennyiben 10 epochot követően nem tud javulni automatikusan leáll. A modelcheckpoint segítségével a validációs adatokon legjobban teljesítő modell mindig lementésre kerül, a tensorboard pedig segít nekünk a tranelés után a modell értékelésben.

#### IV. ÉRTÉKELES

A modell értékeléséhez a teszt adathalmazunkat használtuk fel, amely elemei az eredeti adathalmazból kerültek kiválasztásra randomizált módon, és a tranelés során nem lettek felhasználva. A végső eredmény szemléltetésére egy konfúziós mátrixot is készítettünk:



100%-os eredményt értünk el az adathalmazunkon, így a modell tranelése sikeresnek tekinthető.

#### V. JÖVŐBELI TERVEK

A jövőben több lehetőség is van a modell továbbfejlesztésére.

Izgalmas lehetőség egy újabb osztály hozzáadása a már meglévőkhöz, hogy a modell a tumor típusát is meg tudja mondani (Alzu'bi és mtsai., 2022). A két lehetséges tumor típus a benign és a malignant. Ezek megkülönböztetése rendkívül fontos, hisz míg a benign nem rosszindulatú, nem terjed át más szervekre, és lassabban is növekszik, a malignant rosszindulatú, gyorsan nő, és eltávolítás után is kiújulhat. Amennyiben lehetséges lenne a malignant tumorok felismerése, az ilyen tumorral rendelkező betegek prioritást

nyerhetnének az ellátásuk során, és tovább nőhetne a túlélési esélyük.

A modellt tovább lehetne pontosítani további adathalmazok felhasználásával. Az adathalmaz növeléséhez azonban alkalmazható lenne "image data augmentation" is. Ez azt jelentené, hogy a már meglévő képeket transzformálnánk Opencv segítségével, azaz elforgathatnánk, átméreteznénk, stb.

#### HIVATKOZÁSOK

Alzu'bi, D., Abdullah, M., Hmeidi, I., Al-Azab, R., Gharaibeh, M., El-Heis, M., Almotairi, K. H., Forestiero, A., Hussein, A. M., & Abualigah, L. (2022). Kidney tumor detection and classification based on deep learning approaches: a new dataset in CT scans. *Journal of Healthcare Engineering*, 2022, 1–22. <https://doi.org/10.1155/2022/3861161>

Mehedi, M. H. K., Haque, E., Radin, S. Y., Rahman, M. a. U., Reza, M. T., & Alam, M. (2022). Kidney Tumor Segmentation and Classification using Deep Neural Network on CT Images. *2022 International Conference on Digital Image Computing: Techniques and Applications (DICTA)*. <https://doi.org/10.1109/dicta56598.2022.10034638>

Uhm, K., Jung, S., Choi, M. H., Hong, S., & Ko, S. (2022). A Unified Multi-Phase CT Synthesis and Classification Framework for kidney cancer diagnosis with incomplete data. *IEEE Journal of Biomedical and Health Informatics*, 26(12), 6093–6104. <https://doi.org/10.1109/jbhi.2022.3219123>

Sarvamangala, D.R., Kulkarni, R.V. *Convolutional neural networks in medical image understanding: a survey*. *Evol. Intel.* 15, 1–22 (2022).

Guo, T., Dong, J., Li, H., & Gao, Y. (2017, March). Simple convolutional neural network on image classification. In *2017 IEEE 2nd International Conference on Big Data Analysis (ICBDA)* (pp. 721–724). IEEE.

Ketkar, N. (2017). *Introduction to keras. Deep learning with python: a hands-on introduction*, 97–111.

Zainkó, Cs., & Gyires-Tóth, B. (2021). *Deep Learning a gyakorlatban Python és LUA alapon: Konvolúciós neurális hálózatok előadás*. Budapesti Műszaki és Gazdaságtudomány Egyetem, Budapest.

Sharma, S., Sharma, S., & Athaiya, A. (2017). *Activation functions in neural networks*. *Towards Data Sci*, 6(12), 310–316.

M. R. Ghalib, S. Bhatnagar, S. Jayapoorani, and U. Pande, "Artificial neural network based detection of renal tumors

*using ct scan image processing,” International Journal of Engineering & Technology, vol. 2, no. 1, pp. 28–35, 2014.*

*F. Y. Yap, B. A. Varghese, S. Y. Cen et al., “Shape and texture-based radiomics signature on ct effectively discriminates benign from malignant renal masses,” European Radiology, vol. 31, no. 2, pp. 1011–1021, 2020.*

*F. Zabihollahy, N. Schieda, S. Krishna, and E. Ukwatta, “Automated classification of solid renal masses on contrast-enhanced computed tomography images using convolutional neural network with decision fusion,” European Radiology, vol. 30, no. 9, pp. 5183–5190, 2020.*